Mobil Robot Navigasyonu için Takviyeli Öğrenme ile Hiperparametre Analizi

Demir Mesut ÖZTAŞ

Ankara Üniversitesi, Yapay Zeka Enstitüsü, Yapay Zeka ve Robotik Anabilim Dalı, Ankara, Türkiye

E-posta: demiroztas@gmail.com
GitHub:
https://github.com/DemirMesutOztas/Mobil-Robot-Navigasyonu-icin-Takviyeli-Ogrenme-ile-Hiperparametre-Analizi.git
Youtube:
https://youtu.be/zLa6pR_hq2Q

Özet:

Bu çalışmada, MiniGrid-Empty-8×8-v0 simülasyon ortamında PPO (Proximal Policy Optimization) algoritması kullanılarak bir otonom navigasyon ajanı eğitilmiş ve öğrenme oranı (α), indirim faktörü (γ) ile entropi katsayısı hiperparametrelerinin ajan performansına etkisi dört farklı deney konfigürasyonu üzerinden analiz edilmiştir. Şekillendirilmiş ödül fonksiyonu ile desteklenen eğitim sürecinde öğrenme eğrileri ve son 100 bölümdeki başarı oranları karşılaştırmalı olarak değerlendirilmiştir. Sonuçlar, varsayılan değerlerle ($\alpha=3\times10^{-4}$, $\gamma=0.99$, ent=0.0) tasarlanan referans deneyin en kararlı ve başarılı öğrenmeyi sergilediğini ortaya koymuştur. Öğrenme oranının düşürülmesi yakınsama hızını olumsuz etkilerken indirim faktörünün azaltılması başlangıçta hızlı fakat kararsız bir öğrenmeye, entropi katsayısının artırılması ise test aşamasında genelleme başarısızlığına yol açmıştır. Bu bulgular, hiperparametre seçiminin PPO tabanlı navigasyon sistemlerinde öğrenme kalitesi ve politika kararlılığı üzerinde belirleyici bir rol oynadığını göstermektedir.

Keywords: *PPO, Takviyeli Öğrenme, MiniGrid*

1. Giriş

Mobil robot navigasyonu, otonom sistemlerin belirli bir başlangıç konumundan hedef konumuna engelsiz ve verimli biçimde ulaşabilmesini sağlamaktadır. SLAM (Eş Zamanlı Konumlandırma ve Haritalama), A* ve Dijkstra gibi klasik yol planlama algoritmaları, statik ve önceden bilinen ortamlarda başarılı sonuçlar üretmektedir fakat dinamik, kısmen gözlemlenebilir veya yapılandırılmamış ortamlarda bu yöntemler yetersiz kalabilmektedir [1, 2].

Bu sınırlılıkları aşmak amacıyla Takviyeli Öğrenme (Reinforcement Learning RL) tabanlı yaklaşımlar giderek önem kazanmaktadır. RL'de bir ajan, ortamla etkileşime girerek deneme-yanılma yoluyla ödül sinyallerini maksimize edecek bir politika öğrenmektedir [3]. Bu yaklaşımlar arasında politika gradyan yöntemleri öne çıkmakta olup Schulman ve arkadaşları tarafından 2017'de önerilen Proximal Policy Optimization (PPO), kırpılmış vekil amaç fonksiyonu sayesinde büyük politika güncellemelerini sınırlayarak eğitim kararlılığını sağlamaktadır [4,5].

Takviyeli öğrenme algoritmalarının performansı, hiperparametre seçimlerine önemli ölçüde bağlıdır. Öğrenme oranı (α) politika parametrelerinin güncelleme büyüklüğünü, indirim faktörü (γ) ajanın anlık ödüllere mi yoksa uzun vadeli getirilere mi öncelik vereceğini belirlemektedir. Entropi katsayısı (entropy coefficient) ise politikanın keşif düzeyini kontrol ederek ajanın öğrenme süreci boyunca yeterli keşif yapmasını sağlamaktadır.

Bu çalışmada, MiniGrid-Empty-8×8-v0 simülasyon ortamında bir otonom ajanın PPO algoritmasıyla eğitilmesi ve öğrenme oranı, indirim faktörü ve entropi katsayısı hiperparametrelerindeki değişimlerin ajanın öğrenme hızına ve nihai başarı oranına etkisinin sistematik olarak analiz edilmesi amaçlanmıştır. Çalışmada "Öğrenme oranı, indirim faktörü ve entropi katsayısının farklı kombinasyonları, PPO tabanlı bir navigasyon ajanının yakınsama hızını ve başarı performansını nasıl etkiler?" araştırma sorusuna cevap aranmaktadır.

2. Materyal ve Yöntem

2.1. Simülasyon Ortamı

Bu çalışmada MiniGrid kütüphanesindeki MiniGrid-Empty-8×8-v0 ortamı kullanılmıştır. MiniGrid, takviyeli öğrenme araştırmaları için tasarlanmış, hafif ve modüler bir grid-world ortam koleksiyonudur. Empty-8×8 konfigürasyonu, 8×8 boyutlarında engelsiz bir ızgara haritadan oluşmakta olup görseli Resim 2.1'de yer almaktadır. Ajan, haritanın bir köşesinde başlamakta ve karşı köşedeki yeşil hedef karesine ulaşmayı amaçlamaktadır. Gözlem uzayı, FullyObsWrapper sarmalayıcısı kullanılarak tam gözlemlenebilir hale getirilmiştir. Bu sarmalayıcı sayesinde ajan, ızgaranın tamamını bir matris olarak gözlemleyebilmektedir. Tüm deneyler Google Colab ortamında Python 3 üzerinde yürütülmüştür. [6]

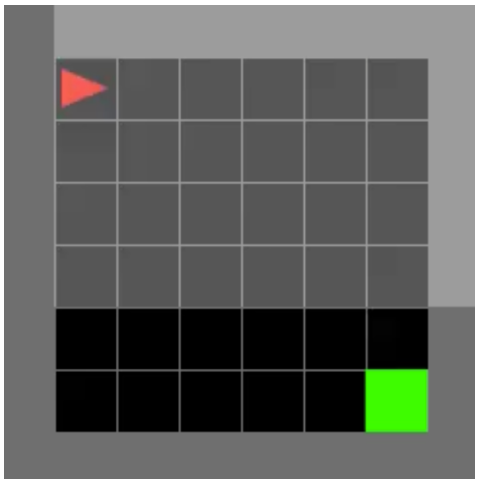

Resim 2.1 Simülasyon Ortamı

2.2 MDP Formülasyonu

Navigasyon problemi bir Markov Karar Süreci (MDP) olarak formüle edilmiştir [3]. MDP, ⟨S, A, T, R, γ⟩ olarak tanımlanmaktadır:

Durum Uzayı (S): FullyObsWrapper ile elde edilen tam ızgara gözlemidir. Her hücre; nesne türü, renk ve durum bilgisi içeren üç kanallı bir gösterimle kodlanmaktadır. Robotun konumu, gözlem matrisinde değeri 10 olan hücre ile belirlenmektedir [6].

Eylem Uzayı (A): Ayrık eylem uzayı, sola dön, sağa dön, ileri git, nesne al, nesne bırak, geçiş yap ve tamamla olmak üzere 7 eylemden oluşmaktadır [6].

Geçiş Fonksiyonu (T): Deterministik geçişler; ajanın seçtiği eylem doğrultusunda konumu ve yönelimi güncellenmektedir.

Ödül Fonksiyonu (R): Temel seyrek ödülün yetersizliğini gidermek amacıyla şekillendirilmiş ödül (reward shaping) mekanizması kullanılmaktadır [8]. Bu araştırmada her adımda −0.01 sabit adım cezası uygulanarak ajanın hedefe en kısa yoldan ulaşması teşvik edilmektedir. Bölüm başarıyla tamamlandığında +10.0 ödül verilmektedir. Ajanın aynı konumda kalması, yani hareketsiz kalma ya da duvara takılma durumu, −1.0 ceza ile engellenmektedir. Hareket gerçekleştiğinde ise robotun hedefe olan Manhattan mesafesi karşılaştırılmakta ve hedefe yaklaşma +0.1, uzaklaşma −0.1 ödül/ceza ile değerlendirilmektedir. Bu çok bileşenli ödül yapısı, seyrek ödül ortamlarında keşfi hızlandırmayı ve politikanın daha erken yakınsammasını sağlamayı amaçlamaktadır .

İndirim Faktörü (γ): Gelecek ödüllerin bugünkü değerini belirleyen katsayı olup deneyler kapsamında 0.99 ve 0.95 değerleri ile test edilmiştir.

2.3. PPO Algoritması

Politika optimizasyonu için Proximal Policy Optimization (PPO) algoritmasının kırpılmış vekil amaç fonksiyonu varyantı kullanılmıştır. PPO, eski ve yeni politika arasındaki oranı kırpma mekanizması ile sınırlayarak büyük politika güncellemelerini engellemekte ve böylece eğitim kararlılığını sağlamaktadır. PPO'nun temel amacı, mevcut verilerle mümkün olan en büyük iyileştirme adımını atarken performans çöküşüne yol açacak kadar büyük adımlardan kaçınmaktır. Bu dengeyi, politika güncelleme oranını $[1-\varepsilon, 1+\varepsilon]$ aralığında kırparak ($\varepsilon = 0.2$) sağlamaktadır [4].

Uygulama, Stable-Baselines3 kütüphanesi üzerinden gerçekleştirilmiştir. Politika ağı olarak MlpPolicy (çok katmanlı algılayıcı) tercih edilmiştir. MlpPolicy, gözlemi düzleştirip tam bağlı katmanlardan geçirerek aktör (politika) ve eleştirmen (değer fonksiyonu) çıktıları üretmektedir [7].

2.4. Deney Tasarımı

Hiperparametrelerin etkisini sistematik olarak değerlendirmek amacıyla dört farklı deney konfigürasyonu oluşturulmuştur. Tablo 2.1'de deney parametreleri özetlenmektedir.

Tablo 2.1. Deney Konfigürasyonları ve Hiperparametre Değerleri

Deney	Öğrenme Oranı (α)	İndirim Faktörü (γ)	Entropi Katsayısı	Toplam Adım
Deney 1 (Referans)	3×10^{-4}	0.99	0.0	100.000
Deney 2	1×10^{-4}	0.99	0.0	100.000
Deney 3	3×10^{-4}	0.95	0.0	100.000
Deney 4	3×10^{-4}	0.99	0.05	100.000

Deney 1, Stable-Baselines3'ün PPO varsayılan değerleri ile referans deney olarak tasarlanmıştır. Deney 2'de öğrenme oranı düşürülerek etkisi incelenmiştir. Deney 3'te indirim faktörü 0.95'e düşürülerek ajanın kısa vadeli ödülleri önceliklendirdiği bir senaryo oluşturulmuştur. Deney 4'te ise entropi katsayısı (ent_coef) 0.05 ayarlanarak politikanın keşif düzeyinin artırılmasının öğrenme performansına etkisi araştırılmıştır.

Hem eğitim hem test aşamasında her bölüm, MiniGrid-Empty-8×8-v0 ortamının varsayılan maksimum adım sınırı olan 256 adımla sınırlandırılmış olup bu süre aşıldığında bölüm başarısız sayılmıştır. Öğrenme sürecini izlemek için her bölüm sonunda ortalama bölüm ödülü ve son 100 bölümdeki başarı oranı kaydedilmiştir. Test aşamasında her model deterministik politika ile 100 bölüm üzerinden değerlendirilmiş ve hedefe ulaşılan bölüm sayısı başarı oranını, toplam ödüllerin ortalaması ise ortalama test ödülünü vermektedir.

Deney sonuçlarının karşılaştırılmasında üç temel metrik kullanılmıştır. Ortalama bölüm ödülü (mean episode reward), değerlendirme adımlarına göre öğrenme eğrisi ve yakınsama hızıdır. Bu metrikler, farklı hiperparametre konfigürasyonlarının öğrenme süreci üzerindeki etkisini çok boyutlu olarak değerlendirmeyi amaçlamaktadır.

3. Bulgular

Gerçekleştirilen pekiştirmeli öğrenme eğitimleri sonucunda farklı hiperparametrelere sahip deneylerin koşulları ve sonuçları Tablo 3.1'de gösterilmektedir. Analiz kapsamında her bir deney için öğrenme oranlarınının zamanla nasıl değiştiğini gösteren karşılaştırmalı grafik Resim 3.1'de gösterilmiş olup en ideal sonucun öğrenme oranı $3x10^{-4}$, indirim faktörü (gamma) 0.99 ve entropi katsayısı 0.0 olarak ayarlanan "Deney 1" sonuçlarının olduğu görülmektedir.

Buna karşılık, öğrenme oranının $1x10^{-4}$ değerine düşürüldüğü "Deney 2" de ajanın mevcut eğitim döngüsü içerisinde yeterince hızlı öğrenemediğini göstermektedir. İndirim faktörünün 0.95'e çekildiği "Deney 3" te ise diğer deneylere göre aslında hızlı bir öğrenme süreci gösterdiği ancak ajanın uzun vadeli hedef olan bölüm sonuna ulaşmaktan ziyade anlık ödüllere odaklanmasından kaynaklı olarak eğitimin son kısımlarında inişli çıkışlı bir hareket izlediği görülmektedir. Son olarak, entropi katsayısının 0.05'e yükseltildiği "Deney 4" te, ajanın aşırı keşif eğilimi göstermesi nedeniyle amacına ulaşamadığı gözlenmiştir.

Tablo 3.1 Karşılaştırmalı Hiperparametre Sonuçları

	Öğrenme Oranı (α)	İndirim Faktörü (γ)	Entropi Katsayısı	Başarı Oranı	Ortalama Ödül
Deney 1	3×10^{-4}	0.99	0.0	100%	9.80
Deney 2	1×10^{-4}	0.99	0.0	0%	-253.06
Deney 3	3×10^{-4}	0.95	0.0	100%	9.80
Deney 4	3×10^{-4}	0.99	0.05	0%	-253.06

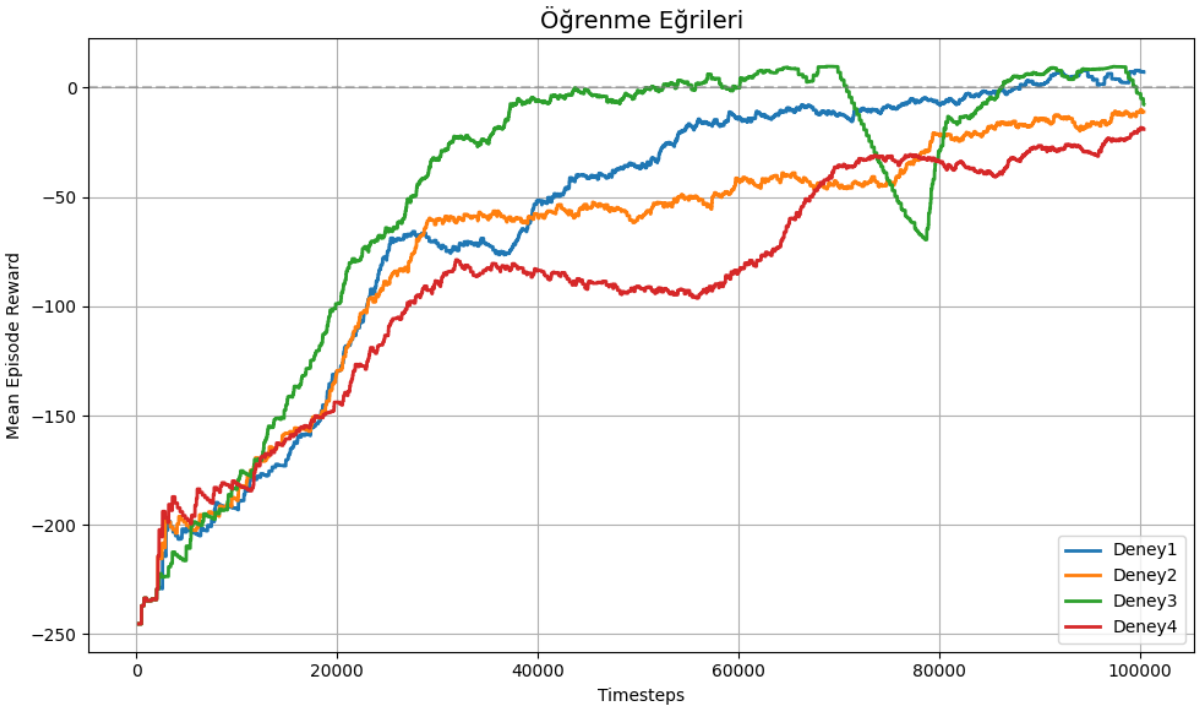

Resim 3.1 Öğrenme Eğrileri

Resim 3.2'de her bir deney ortamının eğitim sürecinde her bölüm bitiminde o ana kadar tamamlanan bölümler üzerinden hesaplanan başarı oranını göstermektedir.

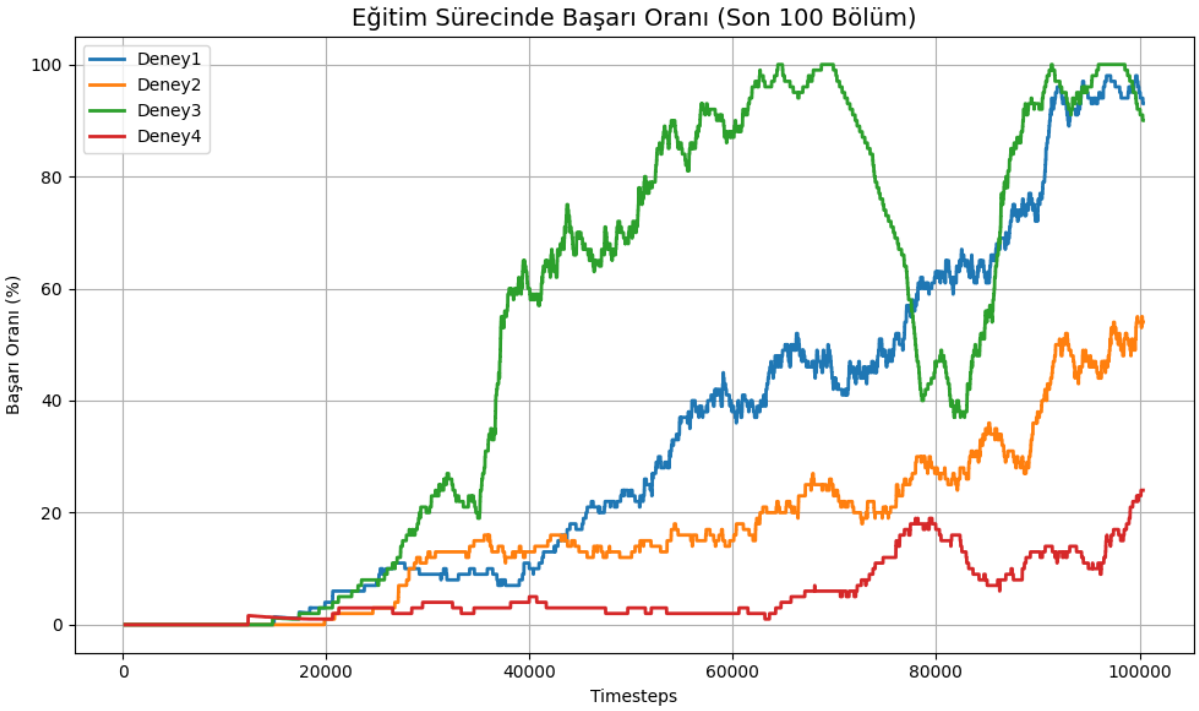

Resim 3.2 Başarı Oranı (Son 100 Bölüm)

Resim 3.3’te farklı koşullara göre eğitilmiş modellerin test ortamında gösterdikleri başarı oranları karşılaştırmalı olarak gösterilmiştir.

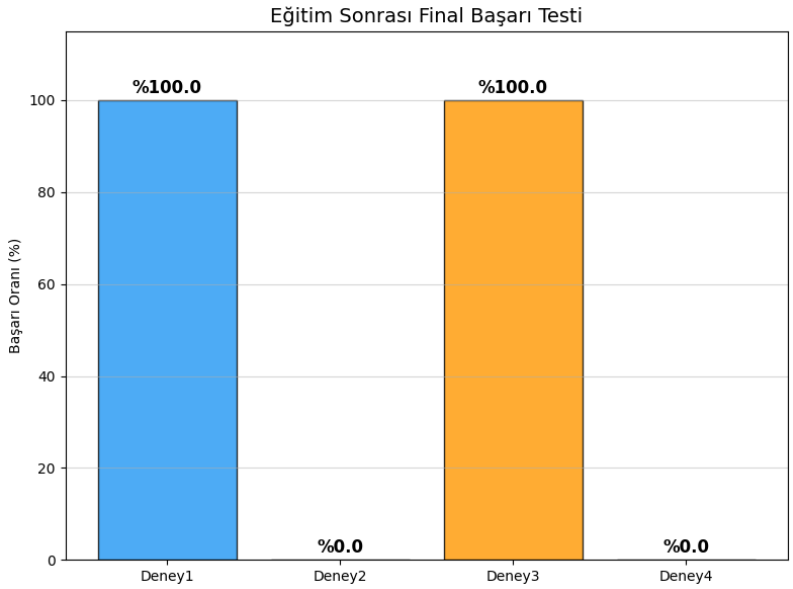

Resim 3.3 Test Başarı Oranları

4. Tartışma ve Sonuç

Bu çalışmada PPO algoritması, dört farklı hiperparametre kombinasyonuyla MiniGrid-Empty-8x8 ortamında eğitilmiş ve sonuçları karşılaştırılmıştır. Yapılana analiz sonucunda elde edilen öğrenme eğrilerine (Resim 3.1) bakıldığında Deney 3 ve Deney1 yaklaşık 0 değerine en hızlı ulaşan modeller olmuştur. Eğitim sürecindeki başarı oranına (Resim 3.2) bakıldığında ise Deney 3'ün (γ=0.95) yaklaşık 35.000 adımda ani bir sıçrama yaparak %100'e ulaştığı fakat grafik geneline bakıldığında dalgalı bir eğitim sürecine sahip olduğu görülmektedir. Bu durumun gamma değerinin düşürülmesi ile modelin daha hızlı öğrenmesine fakat kararlı bir politikaya geç ulaşmasına neden olduğunu göstermektedir. Diğer taraftan Deney1 daha yavaş ama istikrarlı bir artış sergilemiş olup Deney 2 ve Deney 4 ise eğitim boyunca düşük seviyelerde ilerlemiştir.

Ayrıca eğitilmiş modeller test verisi üzerinden analiz edilmiş olup Resim 3.3’te gösterilen modellerin başarı durumuna bakıldığında, Deney1 ve Deney 3 %100 başarıya ulaşırken Deney 2 ve Deney 4 hiç başarılı olamamıştır. Eğitim grafiğinde Deney 2'nin %44–55 bandına ulaşmasına rağmen final testinde %0 çıkması, bu modelin öğrendiği politikanın kararlı test koşullarında genelleme yapamadığına göstermektedir. Deney 4'te ise entropi katsayısının yüksek tutulması modeli eğitim sırasında sürekli keşfe yönelttiği, bu durumun test aşamasında tutarsız davranışa neden olduğunu göstermektedir.

Sonuç olarak en iyi sonucu veren hiperparametre kombinasyonu Deney 1'deki varsayılan değerler (LR=$3x10^{-4}$, γ=0.99, ent=0.0) olmuştur. Öğrenme oranının düşürülmesi modelin verilen adım bütçesi içinde yeterince olgunlaşamamasına, entropi katsayısının artırılması ise keşif dengesinin bozulmasına yol açmıştır. Bu sonuçlar, hiperparametre seçiminin yalnızca öğrenme hızını değil, öğrenilen politikanın kalitesini ve genellenebilirliğini de doğrudan etkilediğini ortaya koymaktadır.

Ek-Yapay Zekâ Etik Kullanım Beyannamesi

Kullanım Alanı	**Kullanılan Araç / Model**	**Amaç**	**Kullanım Düzeyi (Kod/Rapor Yüzdesi)**	**Öğrencinin Kendi Katkısı**
Kod üretimi / düzeltme	Claude	Deney scriptleri, İstatiksel analiz	30%	Simülasyon ortamının kurulması ve scriptlerin çalıştırılması, kodların kullanılan platforma göre güncellenmesi
Hata ayıklama	Claude	Simülasyonda karşılaşılan hataların çözümü	30%	Hata tespiti, uyumsuz durumların değerlendirilmesi
Rapor yazımı / düzenleme	Gemini	Rapordaki hatalı veya yanlış ifadelerin kontrolü, kurulum, kaynakça gibi gibi yapıların oluşturulması	15%	Raporun yazımı, konu başlıkları, içerik yapısı
Teorik kavramlarının açıklanması	Gemini, Consensus	Teorik kavramların öğrenilmesi, literatür taraması, çeviri	50%	İçerik kontrolü ve ilişkilerin değerlendirilmesi
Diğer (Belirtiniz)				

Öğrenci Adı Soyadı: Demir Mesut ÖZTAŞ

Tarih: 25.04.2026

Kaynakça

[1] Thrun, S., Burgard, W., & Fox, D. (2005). *Probabilistic Robotics*. MIT Press.

[2] Hart, P. E., Nilsson, N. J., & Raphael, B. (1968). A Formal Basis for the Heuristic Determination of Minimum Cost Paths. *IEEE Transactions on Systems Science and Cybernetics*, 4(2), 100–107.

[3] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2. Baskı). MIT Press.

[4] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*.

[5] Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2016). High-Dimensional Continuous Control Using Generalized Advantage Estimation. *ICLR*.

[6] Chevalier-Boisvert, M., Willems, L., Pal, S., & et al. (2023). Minigrid & Miniworld: Modular & Customizable Reinforcement Learning Environments. *NeurIPS Datasets and Benchmarks*.

[7] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-Baselines3: Reliable Reinforcement Learning Implementations. *Journal of Machine Learning Research*, 22(268), 1–8.

[8] Ng, A. Y., Harada, D., & Russell, S. (1999). Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *ICML*.